

תרגיל 2 | APML

שם: אריאל ברוך | ת"ז: 205925704

25 בנובמבר 2020

Theoretical Part 1

MLE in the EM algorithm 1.1

התוחלת של ה log likelihood עבור Gaussian mixture model היא:

$$\mathbb{E}[l(S, \theta)] = \sum_{i=1}^N \sum_{y=1}^k c_{i,y} \log(\pi_y N(x_i; \mu_y, \Sigma_y))$$

הראו כי ה MLE של של המשקולות המעורבים הוא אכן:

$$\pi_y = \frac{1}{N} \sum_{i=1}^N c_{i,y}$$

פתרון:

כדי להוכיח את הטענה נרצה להשתמש בשיטת כופלי לאגראנז'. נרצה לעמוד בשני התנאים הבאים:

$$(1) \pi = \operatorname{argmax}_{\pi \in \mathbb{R}} \left\{ \sum_{i=1}^N \sum_{y=1}^k c_{i,y} \log(\pi_y N(x_i; \mu_y, \Sigma_y)) \right\} = \operatorname{argmax}_{\pi \in \mathbb{R}} \left\{ \sum_{i=1}^N \sum_{y=1}^k c_{i,y} \log(\pi_y) + c_{i,y} \log(N(x_i; \mu_y, \Sigma_y)) \right\}$$

$$(2) \sum_{y=1}^k \pi_y = 1$$

ראשית, נבחין כי בביטוי (1) נוכל להתעלם מהביטוי הימני כי הוא לא פונקציה של π . כעת:

$$L(x, y, \lambda) = \sum_{i=1}^N \sum_{y=1}^k c_{i,y} \log(\pi_y) + \lambda \left(1 - \sum_{y=1}^k \pi_y \right)$$

$$\frac{\partial L}{\partial \pi_y} = \frac{\sum_{i=1}^N c_{i,y}}{\pi_y} - \lambda \Rightarrow \lambda = \frac{\sum_{i=1}^N c_{i,y}}{\pi_y} \quad \forall y \in [k]$$

כדי שמה שקיבלנו יהיה נכון, על גלהיות בפרופורציה ל $\sum_{i=1}^N c_{i,y}$ ולכן:

$$\pi_y = \frac{\sum_{i=1}^N c_{i,y}}{\sum_{y=1}^k \sum_{i=1}^N c_{i,y}} = \frac{\sum_{i=1}^N c_{i,y}}{N}$$

כאשר המעבר האחרון נובע מכך שמהגדרה: $\sum_{y=1}^k c_{i,y} = 1$ ואז $\lambda = N$

MLE in GSM algorithm 1.2

מודל GSM מניח שמקטעי התמונות הן דגימות מתוך k גאוסיאנים עם התפלגות $N(0, r_y^2 \Sigma)$ עבור Σ קבועה בין הגאוסיאנים. הראו כי העדכון המקסימלי עבור r_y^2 הוא:

$$r_y^2 = \frac{\sum_{i=1}^n c_{i,y} x_i^T \Sigma^{-1} x_i}{d \sum_{i=1}^n c_{i,y}}$$

פתרון:

בעיית האופטימיזציה היא

$$r_y = \operatorname{argmax}_{r_y \in \mathbb{R}} \left\{ \sum_{i=1}^N \sum_{y=1}^k c_{i,y} \log(\pi_y N(x_i; 0, r_y^2 \Sigma_y)) \right\} = \operatorname{argmax}_{r_y \in \mathbb{R}} \left\{ \sum_{i=1}^N \sum_{y=1}^k c_{i,y} \log(\pi_y) + c_{i,y} \log(N(x_i; 0, r_y^2 \Sigma_y)) \right\}$$

נוכל גם כאן להוריד את המחובר השמאלי שלא כולל את r_y . נקבל:

$$r_y = \operatorname{argmax}_{r_y \in \mathbb{R}} \left\{ \sum_{i=1}^N \sum_{y=1}^k c_{i,y} \log(N(x_i; 0, r_y^2 \Sigma_y)) \right\}$$

נזכור כי:

$$N(x_i; 0, r_y^2 \Sigma_y) = \frac{1}{\sqrt{|2\pi r_y^2 \Sigma_y|}} e^{-\frac{1}{2}(x_i)^T r_y^{-2} \Sigma_y^{-1} (x_i)}$$

נפעיל \log ונקבל:

$$\log N(x_i; 0, r_y^2 \Sigma_y) = -\frac{1}{2} \log(\det(2\pi r_y^2 \Sigma_y)) - \frac{1}{2} (x_i)^T r_y^{-2} \Sigma_y^{-1} (x_i) =$$

$$-\frac{2d}{2} \log(r_y) + \log(\det(2\pi \Sigma_y)) - \frac{1}{2} (x_i)^T r_y^{-2} \Sigma_y^{-1} (x_i)$$

* כי $\det(cA) = c^d \det(A)$ כאשר A מטריצה מממד $d \times d$

נשים לב שהביטוי האמצעי לא כולל את r_y , לכן נרצה למקסם את הביטוי:

$$r_y = \operatorname{argmax}_{r_y \in \mathbb{R}} \left\{ \sum_{i=1}^N \sum_{y=1}^k c_{i,y} \left(-d \log(r_y) - \frac{1}{2r_y^2} (x_i)^T \Sigma_y^{-1} (x_i) \right) \right\}$$

נגזור ונשווה לאפס. נקבל לכל $y \in [k]$:

$$\sum_{i=1}^N c_{i,y} \left(-\frac{d}{r_y} + \frac{1}{r_y^3} (x_i)^T \Sigma_y^{-1} (x_i) \right) = 0$$

$$\sum_{i=1}^N c_{i,y} \left((x_i)^T \Sigma_y^{-1} (x_i) \right) = \frac{r_y^3 \sum_{i=1}^N c_{i,y} d}{r_y}$$

$$r_y^2 = \frac{\sum_{i=1}^n c_{i,y} x_i^T \Sigma^{-1} x_i}{d \sum_{i=1}^n c_{i,y}}$$

כנדרש.

EM Initialization 1.3

יוסי אתחל את EM כך:

$$\forall y : \pi_y = \frac{1}{k}, \mu_y = \mu, \Sigma_y = \Sigma$$

כתבו את שתי האיטרציות הראשונות.

פתרון:

איטרציה 1:

חישוב ה log likelihood:

$$c_{i,y} = \frac{\pi_y N(x_i; \mu_y, \Sigma_y)}{\sum_{l=1}^k \pi_l N(x_i; \mu_l, \Sigma_l)} = \frac{\frac{1}{k} N(x_i; \mu_y, \Sigma_y)}{k \frac{1}{k} N(x_i; \mu_y, \Sigma_y)} = \frac{1}{k}$$

עדכון הפרמטרים:

$$\pi_y = \frac{1}{N} \sum_{i=1}^N c_{i,y} = \frac{1}{N} \sum_{i=1}^N \frac{1}{k} = \frac{1}{k}$$

$$\mu_y = \frac{\sum_{i=1}^N c_{i,y} x_i}{\sum_{i=1}^N c_{i,y}} = \frac{\sum_{i=1}^N \frac{1}{k} x_i}{\sum_{i=1}^N \frac{1}{k}} = \frac{\sum_{i=1}^N x_i}{N} = \bar{x}$$

$$\Sigma_y = \frac{\sum_{i=1}^N c_{i,y} (x_i - \mu_y)(x_i - \mu_y)^T}{\sum_{i=1}^N c_{i,y}} = \frac{\sum_{i=1}^N \frac{1}{k} (x_i - \bar{x})(x_i - \bar{x})^T}{\frac{N}{k}} = \frac{\sum_{i=1}^N \frac{1}{k} (x_i - \bar{x})(x_i - \bar{x})^T}{N} = \bar{\Sigma}$$

איטרציה 2:

חישוב ה log likelihood:

$$c_{i,y} = \frac{\pi_y N(x_i; \mu_y, \Sigma_y)}{\sum_{l=1}^k \pi_l N(x_i; \mu_l, \Sigma_l)} = \frac{1}{k}$$

עדכון הפרמטרים:

$$\pi_y = \frac{1}{N} \sum_{i=1}^N c_{i,y} = \frac{1}{k}$$

$$\mu_y = \frac{\sum_{i=1}^N c_{i,y} x_i}{\sum_{i=1}^N c_{i,y}} = \bar{x}$$

$$\Sigma_y = \frac{\sum_{i=1}^N c_{i,y} (x_i - \mu_y)(x_i - \mu_y)^T}{\sum_{i=1}^N c_{i,y} x_i} = \bar{\Sigma}$$

כלומר, הפרמטרים נשארו כפי שהם ואין עדכון, לכן נרצה שיהיה עירבוב של גאוסיאנים כדי לשפר את יכולת ההבעה של האלגוריתם.

Practical Part 2

אופן ההרצה: עם ערך $k = 5$ ועבור $\epsilon = 0.01, 0.05, 0.1, 0.2$ קבועי רעש. גודל כל patch הוא $[8, 8]$ מתוך התמונה.

2.1 זמני ריצה:

זמן הריצה של המודל GSM משמעותית יותר ארוך מ-MVN כפי שניתן לראות בטבלה הבאה:

	MVN	GSM
learning[sec]	0.0069	4.55
denoising[sec]	89.90	812.06

2.2 :log likelihood

	MVN	GSM
log likelihood	1, 428, 508.688	2, 012, 762.629

2.3 :MSE


ביצועי המודל MVN טובים במעט יותר מאשר GSM:

epsilon	MVN	GSM
0.01	$7.258e - 05$	0.0021
0.05	0.00054	0.0443
0.1	0.0010	0.0419
0.2	0.0018	0.0522

2.4 :denoised images


2.4.1 MVN

אפשר להבחין כי MVN מצליח להתמודד עם הרעש בכל התמונות:



2.4.2 GSM

אפשר להבחין כי ה-GSM מצליח להוריד את הרעש ברוב התמונות למעט התמונה הרועשת ביותר (ימני ביותר) בה יש הבדל נראה לעין לעומת שאר התמונות:



2.5 סיכום:

נבחין כי במרבית הפרמטרים שנבדקו (זמן ריצה, MSE ואיכות שיפור התמונות) אלגוריתם MVN מחזיר תוצאות יותר טובות מגSM. ההבדלים באיכות התוצאה לא מאוד משמעותיים, אבל עצם העובדה שמדובר במודל פשוט יותר שמביא תוצאות טובות יותר הופכת אותו למודל עדיף בהרבה לשימוש. להבנתי מהשוואה מול חברי הקבוצה יש אנשים שקיבלו תוצאות יותר טובות במVN ואחרים בגSM. הייתי מצפה לקבל תוצאות טובות בגSM שכן הוא מודל מורכב יותר שכולל מספר גאוסיינים, ולכן יוכל תיאורטית ללמוד את התפלגות הרעש בצורה טובה יותר ואילו MVN מודל פשוט של גאוסיאן אחד. יתכן שההבדלים בביצועי המודלים תלויי מימוש.